

UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ
DEPARTAMENTO ACADÊMICO DE COMPUTAÇÃO
CURSO DE ENGENHARIA DE COMPUTAÇÃO

EDUARDO DURANTE GODINHO

**IDENTIFICAÇÃO DE DOENÇAS EM FOLHAS DE PLANTAS DE
SOJA UTILIZANDO UMA REDE NEURAL CONVOLUCIONAL**

TRABALHO DE CONCLUSÃO DE CURSO

CORNÉLIO PROCÓPIO
2024

EDUARDO DURANTE GODINHO

IDENTIFICAÇÃO DE DOENÇAS EM FOLHAS DE PLANTAS DE SOJA UTILIZANDO UMA REDE NEURAL CONVOLUCIONAL

Trabalho de Conclusão de Curso apresentado ao Curso de Engenharia de Computação da Universidade Tecnológica Federal do Paraná, como requisito parcial para a obtenção do título de Bacharel.

Orientador: Prof. Dr. Cléber Gimenez Corrêa
Universidade Tecnológica Federal do Paraná

CORNÉLIO PROCÓPIO
2024



4.0 Internacional

Esta é a mais restritiva das seis licenças principais Creative Commons. Permite apenas que outros façam download dos trabalhos licenciados e os compartilhem desde que atribuam crédito ao autor, mas sem que possam alterá-los de nenhuma forma ou utilizá-los para fins comerciais.



TERMO DE APROVAÇÃO

IDENTIFICAÇÃO DE DOENÇAS EM FOLHAS DE PLANTAS DE SOJA UTILIZANDO UMA REDE NEURAL CONVOLUCIONAL

por

Eduardo Durante Godinho

Este Trabalho de Conclusão de Curso de graduação foi julgado adequado para obtenção do Título de “Bacharel” e aprovado em sua forma final pelo Programa de Curso de Engenharia de Computação da Universidade Tecnológica Federal do Paraná.

Cornélio Procópio, 17 de dezembro de 2024

Prof. Dr. Cléber Gimenez Corrêa

Prof. Dr. Claiton de Oliveira

Prof. Dr. Silvio Ricardo Rodrigues Sanches

“A Folha de Aprovação assinada encontra-se na Coordenação do Curso”

Dedico este trabalho a minha família.

AGRADECIMENTOS

Agradeço ao meu orientador Prof. Dr. Cléber Gimenez Corrêa, pela sabedoria com que me guiou nesta trajetória. Aos meus colegas de sala. A Secretaria do Curso, pela cooperação. Gostaria de deixar registrado também, o meu reconhecimento à minha família, pois acredito que sem o apoio deles seria muito difícil vencer esse desafio. Enfim, a todos os que por algum motivo contribuíram para a realização desta pesquisa.

"O verdadeiro método de conhecimento é experimental." - William Blake

RESUMO

GODINHO, Eduardo Durante. IDENTIFICAÇÃO DE DOENÇAS EM FOLHAS DE PLANTAS DE SOJA UTILIZANDO *UMA REDE NEURAL CONVOLUCIONAL*. 2024. 25 f. Trabalho de Conclusão de Curso – Curso de Engenharia de Computação, Universidade Tecnológica Federal do Paraná. Cornélio Procópio, 2024.

A soja, como uma das culturas mais importantes do mundo, enfrenta diversos desafios relacionados à ocorrência de doenças que comprometem sua produtividade e qualidade. Este trabalho tem como objetivo explorar a aplicação de uma técnica de aprendizado de máquina, baseada em uma rede neural convolucional, para a identificação de determinadas doenças em plantas de soja por meio de imagens de folhas. O desenvolvimento do modelo baseou-se em um conjunto de imagens rotuladas por especialistas e representam diferentes condições das folhas, incluindo doenças como ferrugem asiática, mancha-alvo e oídio, além de folhas saudáveis. O conjunto foi dividido para treinamento e teste. O desempenho foi avaliado utilizando métricas como acurácia, neste trabalho com resultado de 70%, F1-Score, com resultado de 0,89, e a matriz de confusão. Os resultados, especialmente da acurácia, foi menor do que o encontrado em trabalhos relacionados. No entanto, os conjuntos de dados desses trabalhos são maiores e acredita-se que esse seja o motivo do baixo valor.

Palavras-chave: doenças, rede neural convolucional, soja.

ABSTRACT

GODINHO, Eduardo Durante. IDENTIFICATION OF DISEASES IN SOYBEAN LEAVES USING UMA REDE NEURAL CONVOLUCIONAL. 2024. 25 f. Trabalho de Conclusão de Curso – Curso de Engenharia de Computação, Universidade Tecnológica Federal do Paraná. Cornélio Procópio, 2024.

Soybean, as one of the most important crops in the world, faces several challenges related to diseases that compromise its productivity and quality. This study aims to explore the application of a machine learning technique, based on a convolutional neural network, for identifying specific diseases in soybean plants through leaf images. The model was developed using a dataset of images labeled by experts, representing different leaf conditions, including diseases such as Asian rust, target spot, and powdery mildew, as well as healthy leaves. The dataset was divided into training and testing sets. Performance was evaluated using metrics such as accuracy, which achieved a result of 70%, F1-Score, with a result of 0.89, and the confusion matrix. The results, particularly the accuracy, were lower than those found in related studies. However, the datasets used in those studies are larger, which is believed to be the main reason for the lower value in this work.

Keywords: Diseases, Convolutional Neural Network (CNN), Soybean.

LISTA DE FIGURAS

Figura 1 – Ferrugem Asiática	3
Figura 2 – Mancha	3
Figura 3 – Pustulas Bacterianas	4
Figura 4 – <i>Heterodera</i>	4
Figura 5 – Figura didática sobre a arquitetura da CNN	7
Figura 6 – Estrutura da matriz de confusão	8
Figura 7 – Ferrugem Asiática	11
Figura 8 – Fusarium	12
Figura 9 – Mancha Alvo	12
Figura 10 – Mancha Olho de Rã	13
Figura 11 – Míldio	13
Figura 12 – Oídio	14
Figura 13 – Saudável	15
Figura 14 – Tabela model.summary	16
Figura 15 – Fluxograma do desenvolvimento do código	18
Figura 16 – Matriz de Confusão	20
Figura 17 – Saudável	21
Figura 18 – Ferrugem	22

LISTA DE TABELAS

Tabela 1 – Distribuição das classes de imagens	11
Tabela 2 – Métricas	17

LISTA DE ABREVIATURAS E SIGLAS

ML	<i>Machine Learning</i>
CNN	<i>Convolutional Neural Network</i>
AUC-ROC	<i>Area Under the Operational Characteristic Curve of the Receiver</i>
SVM	<i>Support Vector Machine</i>
HD	<i>Hard Drive</i>
RAM	<i>Random Access Memory</i>
GB	<i>Gigabyte</i>
DDR	<i>Double Data Rate</i>
TP	<i>True Positive</i>
TN	<i>True Negative</i>
FN	<i>False Negative</i>
FP	<i>False positive</i>

SUMÁRIO

1 – INTRODUÇÃO	1
1.1 Objetivo	1
1.2 Organização do texto	1
2 – FUNDAMENTAÇÃO TEÓRICA	2
2.1 Conjuntos de dados, pré-processamento e ML	2
2.2 Doenças em Plantas de Soja	2
2.3 Tecnologias Tradicionais de Detecção de Doenças em Plantas	5
2.4 ML na Agricultura: Uma Visão Geral	6
2.5 Métricas para Validação	6
2.5.1 Acurácia (Accuracy)	7
2.5.2 Precisão (Precision)	7
2.5.3 Sensibilidade (<i>Recall</i> ou <i>Sensitivity</i>)	7
2.5.4 F1 Score	7
2.5.5 Matriz de Confusão	8
2.5.6 Área Under Curve and Receiver Operating Characteristic (AUC-ROC)	8
2.6 Estratégias para lidar com o desbalanceamentos de classes	9
2.7 TRABALHOS RELACIONADOS	9
2.7.1 Detecção de Doenças Foliares com CNN e Aprendizado Profundo	9
2.7.2 Sistema Aprimorado de Detecção de Doenças Foliares na Soja com Aprendizado Profundo	10
3 – MATERIAIS E MÉTODOS	11
3.1 Conjunto de Dados	11
3.2 Rede Neural Convolucional (CNN)	15
3.3 Avaliação do Modelo	16
3.4 Hardware e Software	16
3.5 Modelo de Rede Neural Convolucional (CNN) Utilizado	16
3.6 Framework Utilizado	17
4 – RESULTADOS E DISCUSSÕES	19
4.1 Desempenho da CNN	19
4.2 Limitações e Implicações Práticas	22
5 – CONCLUSÃO	23
Referências	24

1 INTRODUÇÃO

A soja desempenha um papel crucial na produção global de alimentos e insumos industriais, sendo uma das culturas mais cultivadas no mundo. No entanto, o cultivo da soja enfrenta desafios contínuos, como a ocorrência de diversas doenças, que podem impactar gravemente a produtividade e a qualidade da colheita. Entre as principais ameaças estão doenças causadas por fungos, bactérias e vírus, que podem acarretar perdas econômicas significativas se não forem detectadas e controladas precocemente. Nesse sentido, a detecção, especialmente a detecção precoce dessas doenças, é fundamental para proteger as lavouras e garantir a eficiência da produção (KASHYAP; SHRIVASTAVA; SHARMA, 2022a).

Com os avanços tecnológicos, as técnicas de *Machine Learning* (ML) e processamento de imagens vêm se destacando como ferramentas promissoras no diagnóstico de doenças em plantas. Estudos mostram que algoritmos de aprendizado profundo ou *Deep Learning* são capazes de analisar imagens e identificar padrões que indicam a presença de doenças, muitas vezes em estágios iniciais, antes que os sintomas sejam visíveis a olho nu (KASHYAP; SHRIVASTAVA; SHARMA, 2022a). Esses algoritmos de ML, ao serem alimentados com grandes volumes de dados, podem processar imagens coletadas diretamente no campo, possibilitando diagnósticos automatizados e em tempo real.

Um exemplo significativo da aplicação dessas tecnologias na agricultura pode ser observado no uso de redes neurais convolucionais (CNNs, do inglês *Convolutional Neural Networks*), empregadas para a classificação e diagnóstico de doenças em plantas. Essa abordagem foi explorada em estudos como o de Mohanty (2016), que mostraram como CNNs treinadas com grandes conjuntos de imagens de plantas podem alcançar uma alta taxa de acerto na identificação de doenças. Esses avanços tecnológicos têm o potencial de transformar o manejo agrícola, permitindo intervenções mais precisas e rápidas, reduzindo o uso de pesticidas e promovendo uma agricultura mais sustentável.

1.1 Objetivo

O objetivo deste trabalho é utilizar uma rede neural convolucional para detecção de doenças em plantas de soja baseada em imagens de folhas de soja, procurando melhorar a precisão e a eficiência no diagnóstico.

1.2 Organização do texto

No Capítulo 1 é apresentada a introdução, com uma breve explicação sobre o que será abordado no decorrer do trabalho. No Capítulo 2 é descrita a fundamentação teórica, com os conceitos, teorias e estudos que sustentam e embasam a pesquisa. No Capítulo 3 são abordados os principais trabalhos relacionados, descrevendo trabalhos semelhantes para efeito de comparação. No Capítulo 4 é tratado o desenvolvimento, mencionado como a execução do trabalho foi conduzido. No Capítulo 5 são apresentados resultados e discussões, e por fim, no Capítulo 6 há a conclusão.

2 FUNDAMENTAÇÃO TEÓRICA

Neste capítulo são apresentados conceitos essenciais para a compreensão do trabalho. A construção do conjunto de dados e o pré-processamento das imagens são fatores críticos para a eficácia da pesquisa, assim como a escolha e avaliação dos algoritmos de ML.

2.1 Conjuntos de dados, pré-processamento e ML

A importância da construção de conjuntos de dados robustos é fundamental e não trivial, envolvendo a coleta de imagens variadas e representativas de folhas de soja afetadas ou não por doenças. A rotulação das imagens, na maioria das vezes realizada por especialistas, deve ser realizada para a criação desses conjuntos de dados. Destaca-se também o papel crucial do pré-processamento de imagens para melhorar a qualidade dos dados e aumentar o desempenho dos algoritmos de ML. Neumann (2019) aborda técnicas como normalização e aumento de dados para evitar *overfitting* e melhorar a generalização.

A aplicação de algoritmos de ML na agricultura, especialmente CNNs, pode ser explorada como uma ferramenta promissora para detectar doenças em plantas de soja. Pesquisas recentes mostram que CNNs são eficazes na análise de imagens e no reconhecimento de padrões sutis relacionados a doenças (NEUMANN, 2019).

A importância de avaliar o desempenho dos modelos é destacada, com ênfase em métricas como acurácia, precisão, sensibilidade e F1-score. Estudos recentes enfatizam a relevância de considerar o desequilíbrio de classes em problemas de detecção de doenças.

2.2 Doenças em Plantas de Soja

As plantações de soja são vitais para a segurança alimentar global. No entanto, os agricultores enfrentam uma variedade de doenças que representam desafios significativos na agricultura moderna. Estudos como os de Zuffo (2018) documentam uma diversidade alarmante de patógenos, incluindo fungos, vírus, bactérias e nematoides, todos capazes de prejudicar severamente as plantas de soja.

No caso dos fungos, pode-se destacar a Ferrugem Asiática da Soja, doença causada pelo fungo *Phakopsora pachyrhizi*, uma ameaça grave às colheitas (ZUFFO, 2018). Essa doença cria manchas nas folhas, comprometendo a capacidade fotossintética das plantas. Na Figura 1 é mostrado um caso da ferrugem causada pelo fungo.

Figura 1 – Ferrugem Asiática



Fonte: (CAMPOS, 2008)

No caso dos vírus, há o Vírus do Mosaico da Soja (SMV) (ZUFFO, 2018). O SMV leva ao amarelamento das folhas, reduzindo a produção de clorofila e, consequentemente, a produção de alimentos pela planta. Na Figura 2 é apresentado um caso de mancha-angular.

Figura 2 – Mancha



Fonte: (SILVA, 2021)

Com relação às bactérias, há as patogênicas, como *Xanthomonas axonopodis* pv.

glycines (pústulas bacterianas em soja), que são responsáveis pela Mancha-Angular, uma doença que provoca lesões nas folhas, afetando a fotossíntese e prejudicando a saúde geral da planta, na Figura 3 é apresentado um caso de Pustulas Bacterianas (ZUFFO, 2018).

Figura 3 – Pustulas Bacterianas



Fonte: (SOUZA; OLIVEIRA; OLIVEIRA, 2022)

Por fim, há os nematoides, como *Heterodera glycines*, que são responsáveis pela formação de galhas nas raízes da soja, comprometendo a absorção de nutrientes essenciais (ZUFFO, 2018). Esse dano resulta em perdas significativas na produção. Na Figura 4 é apresentado um caso de *Heterodera*.

Figura 4 – *Heterodera*



Fonte: (SOUZA; OLIVEIRA; OLIVEIRA, 2022)

Essas doenças não apenas reduzem a produção, mas também têm sérias implicações econômicas e ambientais. Os agricultores enfrentam custos adicionais para tratamentos e perdem receitas significativas devido à redução da produção (PEIXOTO, 2000). Adicionalmente, o uso excessivo de produtos químicos para controlar essas doenças leva à poluição do solo e da água, prejudicando os ecossistemas locais.

Em face desses desafios, a pesquisa, como destacada por Nogueira (2020), está se voltando para técnicas inovadoras. A aplicação de algoritmos de ML para análise de imagens oferece esperança na detecção precoce e precisa dessas doenças. Essa abordagem promissora não apenas permite uma identificação rápida, mas também possibilita a implementação de medidas de controle direcionadas, minimizando os impactos econômicos e ambientais. Assim, a integração do conhecimento científico com inovações tecnológicas está se revelando essencial para enfrentar os desafios complexos apresentados pelas doenças nas plantas de soja.

Em síntese, no cenário agrícola contemporâneo, a produção de soja enfrenta uma série de desafios cruciais devido às doenças que afetam as plantações. Uma ampla gama de patógenos, incluindo fungos, vírus, bactérias e nematoides, ataca as plantas de soja, manifestando-se em formas variadas e em diferentes estágios de crescimento (ZUFFO, 2018). Essas doenças não apenas prejudicam diretamente as colheitas, mas também têm impactos econômicos e ambientais significativos. O impacto econômico das doenças em plantas de soja é notório. A redução na produção e nos rendimentos agrícolas resulta em perdas financeiras substanciais para os agricultores e, por extensão, na economia (PEIXOTO, 2000). Além disso, o aumento dos custos devido à necessidade de tratamentos intensivos agrava o cenário econômico, tornando essas doenças um desafio financeiro considerável para a indústria agrícola. Além dos impactos econômicos, as doenças em plantas de soja têm sérias implicações ambientais. O uso excessivo de produtos químicos para controlar essas doenças resulta na poluição do solo e da água, afetando negativamente a biodiversidade local. Esse desequilíbrio ambiental não apenas prejudica o ecossistema, mas também compromete a sustentabilidade a longo prazo da agricultura de soja.

2.3 Tecnologias Tradicionais de Detecção de Doenças em Plantas

A detecção de doenças em plantas de soja tem sido historicamente realizada por meio de métodos tradicionais, que incluem observação visual, testes de campo, análises laboratoriais e inspeções de especialistas. No entanto, essas técnicas enfrentam desafios de subjetividade, tempo e precisão. A observação visual, embora simples, é limitada pela interpretação variável dos sintomas. Os testes de campo proporcionam um ambiente realista, mas podem ser afetados por fatores ambientais. Os testes laboratoriais são precisos, mas demorados e custosos. O uso de indicadores químicos oferece informações básicas sobre a presença da doença, mas não identifica o patógeno específico. As inspeções de especialistas dependem da habilidade individual.

Um dos desafios mais prementes é a detecção precoce e precisa dessas doenças. Métodos tradicionais de detecção, como a observação visual, frequentemente falham devido à variabilidade nas manifestações das doenças (SILVA, 2022). Essa incerteza na identificação das doenças leva a atrasos na implementação de medidas de controle eficazes, resultando em perdas significativas nas colheitas.

Diante desses desafios, a pesquisa se volta para inovações na detecção de doenças em plantas de soja. O uso de algoritmos de ML mostra-se promissor (NOGUEIRA, 2020). A aplicação desses algoritmos na análise de imagens permite uma detecção mais rápida e precisa, fornecendo aos agricultores com informações cruciais para uma gestão proativa das doenças em suas plantações de soja. Essas inovações podem melhorar a produtividade e a sustentabilidade das colheitas de soja.

2.4 ML na Agricultura: Uma Visão Geral

A agricultura moderna está passando por uma transformação significativa devido à incorporação de tecnologias de ML, conforme documentado por estudiosos nessa área (ZHOU, 2021). A aplicação de ML na agricultura está revolucionando não apenas o processo de cultivo, mas também a gestão integral das fazendas, desde o plantio até a colheita e o controle de pragas, doenças e plantas daninhas.

Uma das áreas mais promissoras em que o ML está sendo aplicado é na detecção de doenças em plantas. Estudos recentes, como os de Nogueira (2020) e Silva (2022), destacam a capacidade do ML em analisar imagens de plantas para identificar padrões que indicam a presença de doenças. Algoritmos, como as CNNs, têm demonstrado notável precisão na detecção de doenças em várias culturas, incluindo a soja. Há trabalhos que visam a identificação de doenças em plantas de soja usando CNNs, especialmente analisando imagens das folhas das plantas (JADHAV; UDUPI; PATIL, 2021).

Além da detecção de doenças, o ML é amplamente utilizado na otimização da produção agrícola. Modelos de previsão baseados em ML analisam dados climáticos, padrões de irrigação e condições do solo para oferecer orientações precisas aos agricultores (ZHOU, 2021). Esses modelos possibilitam uma gestão mais eficiente dos recursos, resultando em colheitas mais saudáveis e sustentáveis.

Outra aplicação significativa do ML é na gestão de pragas agrícolas. Sistemas de ML analisam dados em tempo real provenientes de sensores e câmeras para identificar padrões de comportamento das pragas. Essas informações são então utilizadas para implementar estratégias de controle específicas e eficazes, reduzindo a necessidade de pesticidas em larga escala (NOGUEIRA, 2020).


Adicionalmente, o ML desempenha um papel fundamental na automação de tarefas agrícolas. Máquinas equipadas com sensores e algoritmos de ML podem realizar atividades como colheita, plantio e irrigação de forma autônoma, aumentando a eficiência operacional e reduzindo a dependência de mão de obra (ZHOU, 2021).

Essas aplicações de ML na agricultura não apenas otimizam a produção agrícola, mas também contribuem para práticas agrícolas mais sustentáveis e ecológicas. A capacidade do ML em processar grandes volumes de dados, identificar padrões complexos e fornecer resultados interessantes está transformando a agricultura.

2.5 Métricas para Validação

Nesta seção são apresentadas as principais métricas de avaliação de modelos de ML aplicados à detecção de doenças em plantas de soja, bem como as equações que as definem. A correta avaliação dessas métricas é essencial para validar o desempenho de algoritmos de ML, a seguir será mostrado uma imagem com fins didáticos para melhor visualização do funcionamento da CNN que de forma geral é um tipo de rede neural projetada para processar dados em forma de grid, como imagens, composta por camadas convolucionais que aplicam filtros (kernels) para extrair características da imagem, como bordas e texturas. Essas camadas são seguidas por camadas de pooling, que reduzem a dimensionalidade, e camadas totalmente conectadas, responsáveis pela classificação ou regressão final. O objetivo é aprender representações hierárquicas dos dados, permitindo o reconhecimento eficiente de padrões complexos.

Figura 5 – Figura didática sobre a arquitetura da CNN



Fonte: (DATA, 2020)

2.5.1 Acurácia (Accuracy)

A acurácia (equação 1) mede a proporção de previsões corretas em relação ao total de previsões realizadas. No contexto da detecção de doenças, uma alta acurácia indica que o modelo gerado por um algoritmo de ML está acertando a maioria das previsões.

$$Accuracy = \frac{TN + TP}{TP + TN + FP + FN} \quad (1)$$

Onde:

TP = Verdadeiros Positivos (*True Positives*)

TN = Verdadeiros Negativos (*True Negatives*)

FP = Falsos Positivos (*False Positives*)

FN = Falsos Negativos (*False Negatives*)

2.5.2 Precisão (Precision)

A precisão (equação 2) representa a proporção de verdadeiros positivos em relação ao total de previsões positivas feitas pelo modelo. É uma métrica crucial quando é importante minimizar os falsos positivos.

$$Precision = \frac{TP}{TP + FP} \quad (2)$$

2.5.3 Sensibilidade (*Recall* ou *Sensitivity*)

A sensibilidade mede a proporção de verdadeiros positivos em relação ao total de positivos reais. Essa métrica é útil para identificar todas as instâncias positivas e é especialmente importante quando minimizar os falsos negativos.

$$Sensitivity = \frac{TP}{TP + FN} \quad (3)$$

2.5.4 F1 Score


O F1 Score é a média harmônica entre precisão e sensibilidade, oferecendo uma métrica única que equilibra as duas. É particularmente útil em situações de desequilíbrio de classes.

$$F1Score = \frac{2 \times Preciso \times Sensibilidade}{Preciso + Sensibilidade} \quad (4)$$

2.5.5 Matriz de Confusão

A matriz de confusão apresenta uma visão detalhada dos resultados do modelo, mostrando a contagem de verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos. Isso permite uma análise comparativa do desempenho do modelo. Na Figura 6 é apresentado a matriz de confusão obtida.

Figura 6 – Estrutura da matriz de confusão



Fonte: Autoria Própria

2.5.6 Área Under Curve and Receiver Operating Characteristic (AUC-ROC)

A curva ROC e a área sob a curva (AUC) são utilizadas para avaliar o desempenho do modelo em diferentes limiares de decisão. A AUC-ROC varia de 0 a 1, em que um valor próximo de 1 indica um modelo robusto que distingue bem entre classes positivas e negativas.

A interpretação deve ser realizada da seguinte forma:

AUC = 1: Modelo perfeito.

AUC = 0.5: Modelo com desempenho igual ao acaso.

AUC < 0.5: Modelo pior do que um modelo aleatório.

Essas métricas podem ser empregadas para avaliar a eficácia dos modelos de ML na detecção de doenças em plantas de soja, ajudando a garantir a precisão e a confiabilidade dos resultados obtidos.

2.6 Estratégias para lidar com o desbalanceamentos de classes

Existem técnicas que podem ser adotadas para minimizar ou até mesmo erradicar os efeitos negativos que este desbalanceamento acarretaria nos resultados. Para este fim temos, por exemplo, a técnica de Undersampling, que consiste em reduzir o número de exemplos de uma ou mais classes para que haja um equilíbrio as com mais imagens e as com menos imagens, ou podemos também fazer o contrário utilizando a técnica de Oversampling, que seria aumentar a quantidade de exemplos das classes minoritária por meio de cópias ou criação de novas amostras, estes seriam alguns exemplos das formas de se obter melhores resultados(CORDEIRO, 2024).

2.7 TRABALHOS RELACIONADOS

Neste capítulo, o estado da arte sobre a identificação de doenças em plantas é analisado, focando em algoritmos de ML. A detecção precoce é essencial para a saúde das culturas, e a análise de imagens de folhas tem se mostrado eficaz. Inicialmente será apresentado um trabalho que utiliza Máquinas de Vetores de Suporte (SVM) e, em seguida, uma proposta com CNNs. Ao longo do capítulo, são destacadas as semelhanças e diferenças entre as abordagens.

2.7.1 Detecção de Doenças Foliares com CNN e Aprendizado Profundo

(KASHYAP; SHRIVASTAVA; SHARMA, 2022b) O trabalho sobre a identificação de doenças em plantas e o trabalho proposto aqui compartilham vários elementos em comum. Ambos têm como objetivo principal a identificação precisa e eficiente de doenças em culturas, o que é essencial para a saúde das plantas e a produtividade agrícola. Essa análise se baseia na utilização de imagens de folhas, envolvendo fotos de plantas saudáveis e doentes, que são fundamentais para o treinamento e validação dos modelos.

O trabalho relacionado menciona como as tecnologias modernas, como o ML, podem ser eficazes nesse contexto. O uso de técnicas de ML para identificar doenças nas plantas de soja, por meio da análise de imagens, não só melhora a produtividade e a qualidade das colheitas, mas também serve como modelo para outras culturas. O trabalho menciona que os efeitos de fatores bióticos podem levar a doenças fúngicas na soja, resultando em perdas significativas, como olho de sapo (10-60%), ferrugem foliar de Septoria (8-34%) e míldio (9-18%).

O trabalho emprega Máquinas de Vetores de Suporte (SVMs) para criar três modelos diferentes (Grupo 1, Grupo 2 e Grupo 3), combinando recursos de cor e textura. O Grupo 1 demonstrou melhores resultados, com uma precisão de 88%.

A importância do pré-processamento rigoroso das imagens é uma prioridade, garantindo que os modelos sejam treinados com conjuntos de dados diversificados e representativos. Além disso, a ênfase na precisão na identificação de doenças é um ponto crucial, atingindo altas taxas de acerto com SVM.

Por fim, a análise crítica dos resultados obtidos na soja também proporciona conhecimentos valiosos que podem ser transferidos para o estudo de outras culturas. As métricas de avaliação, como acurácia e sensibilidade, são universais e essenciais para a validação de modelos em qualquer contexto agrícola. Com isso, o trabalho sobre soja não apenas aborda uma cultura específica, mas estabelece um alicerce para futuras pesquisas que explorem a aplicação de ML na detecção de doenças em uma variedade de culturas agrícolas. Essas semelhanças evidenciam uma continuidade na busca por soluções inovadoras para os desafios enfrentados na agricultura,

unindo técnicas tradicionais de ML com novas tecnologias para melhorar a detecção e o manejo de doenças nas culturas.

2.7.2 Sistema Aprimorado de Detecção de Doenças Foliares na Soja com Aprendizado Profundo

([SUVARNA et al., 2023](#)) O método proposto apresenta um resultado com uma precisão de 95,09%, evidenciando a eficácia da arquitetura de treinamento com AlexNet CNN, que exhibe características promissoras de desempenho em validação, incluindo um bom desempenho de treinamento, análise por meio da matriz de confusão e a curva ROC.

A utilização de CNNs para classificar e diagnosticar doenças em soja é replicável em outras culturas, como milho, arroz e trigo. Esses métodos podem ser adapta-dos para processar imagens de folhas e frutos, identificando doenças semelhantes e respondendo a diferentes condições ambientais. Neste trabalho foi utilizado um dataset que abrange mais de 14 espécies de cultivo e tem aproximadamente 87.000 fotos de plantas saudáveis e doentes, para treinar o modelo Multi-class SVM utilizou-se 320 fotografias, cerca 80 imagens de cada categoria de doença, um modelo classificador que foi construído é validado usando cerca de 15% dos dados da imagem, resultando em uma precisão de 93,75%.

3 MATERIAIS E MÉTODOS

Neste capítulo são descritos os principais métodos e materiais, incluindo o algoritmo de ML e conjunto de dados.

3.1 Conjunto de Dados

Temos na Tabela 1, a divisão do conjunto de dados composto por imagens de folhas de soja, cada imagem no conjunto de dados possui rótulos que indicam a presença ou ausência de doenças específicas, como ferrugem asiática e mofo branco. É composto por 7 classes, sendo elas: Ferrugem com 449 imagens, Saudáveis com 74 imagens, Fusarium com 8 imagens, Mancha Alvo com 25 imagens, Mancha Olho de Rã com 222, Míldio com 265 imagens e Oídio com 348.


Tabela 1 – Distribuição das classes de imagens

Classes	Ferrugem	Fusarium	Míldio	Oídio	Mancha Alvo	Mancha Olho de Rã	Saudáveis
Quantidade	449	8	265	348	25	222	74

Para garantir a confiabilidade dos resultados, o conjunto de dados foi dividido em dois subconjuntos: treinamento e teste. A divisão foi feita de forma aleatória, porém para assegurar uma representação equilibrada de todas as classes de doenças, em trabalhos futuros, poderíamos utilizar algumas das técnicas citadas na fundamentação teórica. O subconjunto de treinamento correspondeu a 80% dos dados, enquanto o subconjunto de teste representou os 20% restantes.


Nas Figuras 7, 8, 9, 10, 11, 12 são apresentadas as doenças Ferrugem Asiática, Fusarium, Mancha Alvo, Mancha Olho de Rã, Míldio e Oídio, com pequenos círculos em vermelho destacando as partes infectadas quando necessário. Na Figura 13 é apresentado um exemplar de uma folha Saudável.

Figura 7 – Ferrugem Asiática




Fonte: Autoria Própria

Figura 8 – Fusarium




Fonte: Aatoria Própria

Figura 9 – Mancha Alvo




Fonte: Aatoria Própria

Figura 10 – Mancha Olho de Rã



Fonte: Autoria Própria

Figura 11 – Míldio




Fonte: Autoria Própria

Figura 12 – Oídio



Fonte: Autoria Própria

Figura 13 – Saudável



Fonte: Autoria Própria

3.2 Rede Neural Convolucional (CNN)

Este estudo adotou uma abordagem baseada em CNNs. Inspirados por trabalhos anteriores, como os de Nogueira (2020) e Silva (2022), uma CNN foi implementada para detectar doenças em plantas de soja.

O modelo desenvolvido consiste em uma Rede Neural Convolucional (CNN) definida para classificação de imagens em um conjunto de dados com múltiplas categorias. As imagens foram redimensionadas para 128×128 pixels com três canais (RGB ou Red, Green e Blue) e normalizadas para valores entre 0 e 1. A arquitetura da rede é composta por três blocos de camadas convolucionais e de *pooling*, seguidos por camadas densas para classificação (Max uma camada *Flatten*, uma camada densa com 128 neurônios e uma camada de saída com número de neurônios correspondente às classes do problema, função ativação Sigmóide e função de perda *Binary Crossentropy*, adequada para classificação multi-rótulo, feita com o one hot encoding. O treinamento foi realizado com o otimizador Adam (taxa de aprendizado de 0,001), 25 épocas, e *batch size* de 64. O modelo foi avaliado em termos de precisão, revocação e F1-Score, além de matriz de confusão para análise detalhada das predições, a seguir temos uma figura que ilustra de forma mais didática a composição da rede neural desenvolvida, como por exemplo o número de camadas, funções de ativação, entrada, saída entre outros.

Figura 14 – Tabela model.summary

	PRIMEIRA	SEGUNDA	TERCEIRA		PRIMEIRA	SEGUNDA	TERCEIRA		TOTALMENTE CONECTADA	DE SAÍDA
CAMADAS	Conv2D	Conv2D	Conv2D		MaxPooling2D	MaxPooling2D	MaxPooling2D	Flatten	Dense	Dense
FILTROS	32	64	128	TAMANHO DA JANELA	2, 2	2, 2	2, 2			
TAMANHO DO FILTRO	3, 3	3, 3	3, 3	ENTRADA	128, 128, 32	64, 64, 64	32, 32, 128			
FUNÇÃO DE ATIVAÇÃO	ReLU	ReLU	ReLU	SAÍDA	64, 64, 32	32, 32, 64	16, 16, 128		ReLU	Sigmoid
ENTRADA	128, 128, 32	64, 64, 32	32, 32, 64	PARÂMETROS TREINÁVEIS	0	0	0	16, 16, 128	32,768	128
SAÍDA	128, 128, 32	64, 64, 64	32, 32, 128					32, 768	128	num_classes
PARÂMETROS TREINÁVEIS	896	18,496	73,856					0	4,194,304	num_classes * 128 + 1
UNIDADES									128	num_classes

Fonte: Autoria Própria

3.3 Avaliação do Modelo

A avaliação do modelo foi realizada utilizando um conjunto de métricas, conforme orientações de Zhou (2021) e Silva (2022). Essas métricas permitiram uma análise detalhada do desempenho do modelo na detecção de doenças em plantas de soja. As métricas selecionadas foram: Acurácia, Revocação, F1-Score, e Matriz de Confusão.

3.4 Hardware e Software

Neste trabalho foi utilizada uma máquina para implementação e execução do algoritmo de classificação, a qual possui a seguinte configuração: um processador i7 de sétima geração com chipset integrado, um SSD de 128 GB e um HD de 1 tera, dois pentes de memória RAM 8 GB DDR4. Foi utilizado como software de codificação o Visual Studio Code e como linguagem de programação foi utilizado Python e no código encontramos as seguintes bibliotecas:

NumPy: Para manipulação de arrays, especialmente no processamento de imagens e preparação dos dados para o modelo.

Pandas: Para ler e manipular o arquivo CSV que contém os caminhos das imagens e seus rótulos.

TensorFlow/Keras: Para construir e treinar o modelo de rede neural convolucional (CNN), utilizando camadas como Conv2D, MaxPooling2D, Dense e o otimizador Adam. Além disso, é usado para converter rótulos para o formato one hot encoding.

3.5 Modelo de Rede Neural Convolucional (CNN) Utilizado

O modelo de rede neural convolucional (CNN) utilizado neste trabalho é personalizado, ou seja, foi criado e treinado do zero para a tarefa específica. No processo de construção do modelo, cada camada convolucional foi projetada para aprender características importantes das imagens de entrada. As camadas de pooling foram usadas para reduzir a dimensionalidade das representações intermediárias e manter as características mais relevantes. Por fim, a rede termina com camadas densas que realizam a classificação das imagens em uma ou mais categorias, dependendo da aplicação.

O fato de o modelo ser personalizado significa que ele não se beneficia de conhecimento prévio, como o aprendizado de características em grandes datasets como o ImageNet, que é comum em modelos pré-treinados. Em vez disso, o treinamento do modelo é realizado a partir dos dados fornecidos neste trabalho, o que pode resultar em um tempo de treinamento maior, além de depender fortemente da qualidade e da quantidade do conjunto de dados disponível.

3.6 Framework Utilizado

O modelo foi implementado utilizando o TensorFlow, com a API Keras como ferramenta de alto nível para a construção e treinamento da rede neural. O Keras facilita a criação de modelos complexos de redes neurais de maneira simples e eficiente, sendo amplamente utilizado no campo da inteligência artificial para problemas de visão computacional, como a classificação de imagens.

O uso do TensorFlow com Keras permite uma execução otimizada e eficiente do modelo, aproveitando os recursos computacionais para acelerar o treinamento. A biblioteca oferece uma ampla gama de camadas e funcionalidades, como as camadas convolucionais (Conv2D), camadas de pooling (MaxPooling2D), funções de ativação (ReLU, Sigmoid), e otimização (Adam), todas utilizadas no desenvolvimento do modelo, na sequência será apresentado por meio de figuras as métricas com seus respectivos resultados e um fluxograma sobre o desenvolvimento do código para melhor entendimento de como o mesmo foi desenvolvido, sendo que para uma breve explicação temos:


O processo inicia com a preparação dos dados e do modelo, então ele carrega o conjunto de dados a ser utilizado no modelo, então temos a etapa de pré-processamento das imagens que são ajustadas (como redimensionamento, normalização) para serem compatíveis com o modelo, então são convertidos os rótulos para codificação one-hot encoding transformados em uma representação numérica adequada para a rede neural, então o conjunto de dados é dividido dados em treino e teste para treinar e avaliar o modelo, então cria-se o modelo CNN, então o modelo é compilado, é configurado com o otimizador, a função de perda e as métricas de avaliação, então é treinado com os dados de treino, testado com dados de teste para verificar seu desempenho, são carregadas as imagens teste para prever sua classe, onde o modelo realiza a predição da classe da imagem fornecida, temos então a saída de classe prevista, a exibição da mesma, por fim o resultado da predição é exibido, mostrando a classe prevista da imagem.

Este processo é um pipeline completo para desenvolver, treinar, testar e utilizar uma CNN em problemas de classificação de imagens, a seguir temos na tabela 2 o resultado obtido para cada métrica.

Tabela 2 – Métricas

MÉTRICAS	ACURÁCIA	SENSIBILIDADE	F1-SCORE	PRECISÃO
VALOR	70%	88%	0,89	80%

Figura 15 – Fluxograma do desenvolvimento do código



Fonte: Autoria Própria

4 RESULTADOS E DISCUSSÕES

No presente capítulo, são apresentados e discutidos os resultados obtidos por meio da análise dos dados coletados ao longo da pesquisa.

4.1 Desempenho da CNN

As métricas de avaliação, conforme descritas na Seção 2.4, foram calculadas para o algoritmo. Os resultados obtidos empregando métricas possibilitam a determinação da eficácia da CNN para a detecção de doenças em plantas de soja. No entanto, o conjunto de dados também têm influência nos resultados.

O modelo apresentou uma acurácia de 70% nos testes, indicando que 70% das previsões positivas estavam corretas. Essa taxa de acerto provavelmente foi devido ao número reduzido de imagens em algumas classes do conjunto de dados.

Em uma comparação das duas abordagens dos trabalhos relacionados para a identificação de doenças em plantas, com foco em soja, utilizando técnicas de ML temos, O primeiro estudo emprega SVMs, enquanto o segundo adota CNNs. Ambos visam melhorar a detecção e o manejo de doenças nas culturas, mas utilizam metodologias distintas, resultando em diferentes métricas e resultados ([KASHYAP; SHRIVASTAVA; SHARMA, 2022b](#)).

No estudo com SVMs foram desenvolvidos três modelos, combinando características de cor e textura das imagens de folhas, alcançando uma precisão de 88% no reconhecimento de doenças como olho de sapo, ferrugem foliar de Septoria e míldio. O estudo com CNNs, inspirado em trabalhos anteriores, utiliza uma rede composta por camadas convolucionais e pooling, seguida por camadas densas para a classificação multi-rótulo. O treinamento foi conduzido com o otimizador Adam e as métricas de avaliação incluíram precisão, revocação, F1-Score e matriz de confusão, focando em uma análise detalhada do desempenho.

Ambos os estudos destacam a importância do pré-processamento rigoroso das imagens, como redimensionamento e normalização, para garantir a qualidade dos dados e a eficácia dos modelos. As métricas utilizadas, como precisão e F1-Score, são cruciais para avaliar a performance dos modelos em problemas de classificação multi-rótulo. Embora o estudo com SVMs tenha demonstrado boa precisão, o modelo baseado em CNNs oferece uma abordagem mais profunda e sofisticada, com potencial para adaptação a outras culturas agrícolas.

Já comparando o segundo trabalho relacionado sobre a detecção de doenças em plantas de soja utilizando técnicas de Machine Learning, temos que no presente trabalho adota-se uma abordagem baseada em Redes Neurais Convolucionais (CNNs) e obteve uma precisão de 95,09%. A CNNs foi treinada com um grande conjunto de dados, incluindo mais de 87.000 imagens de plantas saudáveis e doentes, e foi validada utilizando métricas como precisão, revocação, F1-Score, matriz de confusão e curva ROC. O modelo mostrou-se adaptável a outras culturas, como milho, arroz e trigo, e destacou-se pela capacidade de identificar doenças com alta precisão, além de se adaptar a diferentes condições ambientais.

O segundo estudo utilizou Máquinas de Vetores de Suporte (SVMs) para classificar doenças em soja. O modelo foi treinado com 320 imagens e alcançou uma precisão de 93,75%, utilizando 15% dos dados para validação. Embora tenha apresentado bom desempenho, o estudo sugeriu que a performance poderia ser aprimorada com um maior volume de dados ([SUVARNA et al., 2023](#)).

Ambos os estudos utilizaram métricas como precisão, revocação e F1-Score para avaliar o desempenho dos modelos. A matriz de confusão foi aplicada em ambos os casos,


permitindo uma análise detalhada das predições. O estudo com CNNs, mostrou-se mais robusto e flexível, com potencial para ser aplicado em diferentes culturas, enquanto o modelo baseado em SVMs, apesar de eficaz, foi limitado pelo menor número de imagens usadas no treinamento. Ambos os métodos evidenciam o potencial das técnicas de ML para melhorar a detecção de doenças nas plantas, com a CNN se destacando pela adaptabilidade e precisão.

Em síntese, enquanto o estudo com o conjunto de dados maior explorou uma abordagem multi-espécies, este trabalho foca especificamente na soja, com uma análise mais detalhada e equilibrada das categorias de doenças presentes, reforçando a replicabilidade do método para outras culturas agrícolas.

Continuando a análise, o resultado da métrica sensibilidade foi de 88%, revelando a capacidade do modelo em identificar corretamente as doenças presentes nas plantas. A F1-Score alcançou 0,89, demonstrando um bom equilíbrio entre precisão e sensibilidade.

A matriz de confusão, apresentada na Figura 16, fornece uma visão detalhada do desempenho do modelo, possibilitando identificar em quais pontos ocorreram erros de classificação. Os falsos negativos, embora em menor número, representam uma área de melhoria, visto que a subestimação de doenças pode resultar em perdas significativas na produtividade.

Figura 16 – Matriz de Confusão



Fonte: Autoria Própria

Para facilitar o entendimento da matriz de confusão temos o mapeamento de rótulos para as classes sendo 0 para Ferrugem, 1 para Saudáveis, 2 para Fusarium, 3 para Mancha Alvo, 4 para Mancha Olho, 5 para Míldio e 6 para Oídio.


Pode-se citar como exemplo de um possível erro do modelo a seguinte situação: uma imagem de folha com uma mancha pequena pode ser entendida como saudável, visto que a anomalia é tão pequena que poderia não ser considerada pelo modelo como uma doença. Como sugestão o redimensionamento das as imagens antes da leitura tornaria visível essas anomalias, para que fica mais claro na sequencia temos imagens para ilustrar a proximidade visual.

Figura 17 – Saudável



Fonte: Autoria Própria

Figura 18 – Ferrugem



Fonte: Autoria Própria

4.2 Limitações e Implicações Práticas

Os resultados indicam que há a necessidade de um conjunto maior de dados, para a implementação de um modelo de identificação de doenças robusto para as práticas agrícolas. O diagnóstico preciso permite intervenções que podem reduzir a necessidade de tratamentos químicos, que poderão ser realizados em pontos específicos da propriedade, contribuindo para uma agricultura mais sustentável e economicamente viável ao minimizar perdas e otimizar o uso de recursos.

Uma outra limitação está relacionada à necessidade de especialistas, como por exemplo agricultores da cultura de soja, para rotular as imagens e possibilitar o aprendizado. Adicionalmente, doenças podem ter diferentes estágios, com diferentes formas de afetar a folha da planta de soja.

5 CONCLUSÃO

O presente estudo explorou a aplicação de técnicas de ML, especialmente CNNs, para a detecção de doenças em plantas de soja por meio de imagens de folhas. A pesquisa evidenciou a relevância de abordagens tecnológicas na superação dos desafios enfrentados na agricultura, especialmente em relação à detecção de doenças.

O uso de CNNs consiste em uma técnica que pode ser empregada na identificação de padrões complexos em imagens, permitindo alcançar altos níveis de acurácia e confiabilidade na classificação das condições das folhas de soja, conforme pode-se observar o estado da arte. A divisão do conjunto de dados em classes representativas, com diferentes manifestações de doenças como ferrugem asiática, mancha-alvo e oídio, é crucial para criar modelos a partir dessa técnica. Além disso, o uso de técnicas de pré-processamento e a avaliação detalhada com detalhes como F-Score e matriz de confusão possibilitam a validação da aplicação da técnica.

Os resultados obtidos, especialmente em relação à acurácia, indicam um menor valor em comparação com os trabalhos relacionados. Apesar dos avanços em algoritmos de ML, este estudo evidencia determinados desafios, como o desequilíbrio de classes no conjunto de dados e a dependência de imagens rotuladas manualmente por especialistas. Essas questões abrem espaço para futuras pesquisas, que podem explorar estratégias de balanceamento de dados e ampliação de conjuntos de dados.

Em síntese, a integração de inovações tecnológicas como o ML na agricultura é relevante para enfrentar os desafios impostos por doenças nas plantações de soja. Futuras pesquisas devem explorar a combinação de técnicas de ML com dados temporais e ambientais, além de integrar sensores IoT para a coleta em tempo real de dados sobre as condições das plantações. A utilização de métodos de *ensemble* também pode ser uma abordagem interessante para melhorar ainda mais a precisão do diagnóstico.

Referências

- CAMPOS, M. F. D. Análise de crescimento em plantas de soja tratadas com substâncias reguladoras. **Revista Biotemas**, v. 21, n. 3, 2008. Citado na página 3.
- CORDEIRO, T. V. B. **PREDIÇÃO DE DEFAULT DE EMPRESAS: TÉCNICAS DE MACHINE LEARNING EM DADOS DESBALANCEADOS**. 2024. Acesso em: 19 dez. 2024. Disponível em: <<https://repositorio.fgv.br/server/api/core/bitstreams/2b4515b8-f04f-4e5c-8e21-debdd7c18e99/content>>. Citado na página 9.
- DATA, I. **Redes Neurais Convolucionais**. 2020. Acesso em: 18 dez. 2024. Disponível em: <<https://medium.com/itau-data/redes-neurais-convolucionais-2206a089c715>>. Citado na página 7.
- JADHAV, S.; UDUPI, V.; PATIL, S. Identification of plant diseases using convolutional neural networks. **International Journal of Information Technology**, v. 13, p. 2461–2470, 2021. Citado na página 6.
- KASHYAP, Y.; SHRIVASTAVA, S. S.; SHARMA, R. An improved soybean foliar disease detection system using deep learning. In: **2022 IEEE Conference on Interdisciplinary Approaches in Technology and Management for Social Innovation (IATMSI)**. [S.l.: s.n.], 2022. p. 1–6. Citado na página 1.
- KASHYAP, Y.; SHRIVASTAVA, S. S.; SHARMA, R. An improved soybean foliar disease detection system using deep learning. In: **2022 IEEE Conference on Interdisciplinary Approaches in Technology and Management for Social Innovation (IATMSI)**. [S.l.: s.n.], 2022. p. 1–6. Citado 2 vezes nas páginas 9 e 19.
- NEUMANN, B. G. **Identificação de doenças na soja utilizando inteligência artificial por meio de análise de imagens**. Dissertação (Master's thesis) — Nome da instituição, 2019. Citado na página 2.
- NOGUEIRA, L. C. A. Machine learning (ml) para detecção de *pratylenchus brachyurus* na cultura da soja utilizando imagens msi/sentinel-2. 2020. Citado 2 vezes nas páginas 5 e 6.
- PEIXOTO, C. P. Épocas de semeadura e densidade de plantas de soja: I. componentes da produção e rendimento de grãos. **Scientia Agricola**, v. 57, p. 89–96, 2000. Citado na página 5.
- SILVA, F. d. A. **Detecção de doenças e/ou praga em plantas utilizando aprendizado de máquina**. Dissertação (Master's thesis), 2022. Citado na página 5.
- SILVA, G. V. G. Bachelor's thesis, **Detecção de doenças em folhas de soja utilizando redes neurais convolucionais**. Cidade, País: [s.n.], 2021. Citado na página 3.
- SOUZA, T. A. D.; OLIVEIRA, L. F. D.; OLIVEIRA, C. C. D. Uso da ti e machine learning (ml) para ajudar no combate ao percevejo marrom. **Advances in Global Innovation & Technology**, v. 1, n. 1, 2022. Citado na página 4.

SUVARNA, T. S. L. et al. Enhancing crop health by identifying leaf disease with high accuracy using cnn. In: **2023 Third International Conference on Secure Cyber Computing and Communication (ICSCCC)**. [S.l.: s.n.], 2023. p. 403–408. Citado 2 vezes nas páginas 10 e 19.

ZHOU, Z.-H. **Machine Learning (ML)**. [S.l.]: Springer Nature, 2021. Citado na página 6.

ZUFFO, A. M. Correlações e análise de trilha em cultivares de soja cultivadas em diferentes densidades de plantas. **Revista Cultura Agronômica**, v. 27, n. 1, p. 78–90, 2018. Citado 4 vezes nas páginas 2, 3, 4 e 5.