

Segmentação de Insetos Camuflados e de Pequena Escala utilizando Fusão de Fluxo Óptico em Redes Neurais Convolucionais

1st Jean Marcel Peres Martins

Programa de Pós-graduação em Informática (PPGI)
UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ (UTFPR)
Cornélio Procópio, Brasil
jeanmarcel8@gmail.com

Abstract—A detecção automatizada de pragas constitui um desafio crítico na Agricultura de Precisão, dificultada pelas dimensões reduzidas dos vetores e pela complexidade dos fundos agrícolas. Este obstáculo é exacerbado quando o objeto de interesse apresenta mimetismo cromático com o substrato foliar. Este trabalho investiga a eficácia de Redes Neurais Convolucionais (CNNs) na segmentação semântica de insetos sob condições variadas de contraste cromático, variando de alta distinção (insetos vermelhos/pretos) a camuflagem total (insetos verdes). A metodologia compreende três experimentos comparativos: (1) Baseline utilizando a arquitetura U-Net com entrada RGB; (2) U-Net submetida a Data Augmentation extensivo; e (3) uma arquitetura híbrida proposta, com topologia modificada para processamento de 6 canais (RGB concatenado com Fluxo Óptico Denso). Os resultados experimentais demonstram que abordagens fundamentadas exclusivamente em características espaciais falham na convergência, tendendo à classe majoritária (fundo) devido ao severo desbalanceamento de classes, independentemente do contraste espectral. Em contrapartida, a arquitetura híbrida proposta obteve sucesso na segmentação em todos os cenários, validando a dinâmica temporal como uma *feature* discriminante superior à informação espectral para a detecção de objetos de pequena escala em ambientes não estruturados.

Index Terms—Visão Computacional, Segmentação Semântica, Fluxo Óptico, U-Net, Camuflagem, Deep Learning.

I. INTRODUÇÃO

A implementação efetiva de estratégias de Manejo Integrado de Pragas (MIP) na Agricultura de Precisão é intrinsecamente dependente da robustez de sistemas de Visão Computacional na detecção de agentes biológicos em ambientes não estruturados. O estado da arte em segmentação semântica, atualmente dominado por arquiteturas baseadas em Redes Neurais Convolucionais (CNNs) como U-Net e Mask R-CNN, demonstra desempenho notável na identificação de objetos macroscópicos. Entretanto, observa-se uma degradação abrupta na acurácia em duas condições críticas: (1) *Small Object Detection*, onde a Região de Interesse (RoI) ocupa uma área residual da imagem ($< 1\%$); e (2) Camuflagem Cromática, cenário em que os histogramas de cor e textura do alvo apresentam alta correlação estatística com o *background* (substrato foliar).

Este estudo investiga a intersecção destes desafios, abordando a segmentação de insetos que exibem, simultaneamente, dimensões reduzidas e mimetismo severo. A hipótese central deste trabalho postula que, em cenários onde a informação visual estática (domínio espacial RGB) se torna ambígua ou insuficiente, a dinâmica temporal (fluxo de movimento) atua como uma *feature* discriminante invariante à camuflagem.

As principais contribuições deste trabalho são:

- 1) Curadoria de um *dataset* anotado que abrange desde cenários de alto contraste (controle: *Red/Black*) até condições de camuflagem crítica (desafio: *Green*).
- 2) Desenvolvimento de um *pipeline* de supervisão fraca (*weak supervision*) para a geração automática de *Ground Truth* através de algoritmos de subtração de fundo baseados em Mistura de Gaussianas.
- 3) Proposta e validação de uma arquitetura U-Net híbrida, modificada para realizar a fusão de dados espaciais e temporais (Fluxo Óptico Denso), visando mitigar o severo desbalanceamento de classes inerente ao problema.

A. Aquisição e Preparação do Dataset

A constituição da base de dados fundamentou-se na captura de sequências de vídeo em ambiente controlado, simulando o deslocamento de um inseto sobre substrato foliar (*Musa* spp.). O material audiovisual foi submetido a um processo de decomposição temporal, resultando na extração de aproximadamente 1.500 quadros estáticos (*frames*) por cenário experimental.

Os dados foram categorizados em três subconjuntos distintos para isolar as variáveis de contraste e camuflagem:

- 1) **Dataset Red (Desafio 1):** Inseto de coloração vermelha sobre folha verde, caracterizando alto contraste cromático[cite: 30].
- 2) **Dataset Black (Desafio 2):** Inseto de coloração preta sobre folha verde, caracterizando alto contraste de luminância[cite: 31].
- 3) **Dataset Green (Desafio 3):** Inseto de coloração verde sobre folha verde, apresentando mimetismo cromático e textural completo com o substrato[cite: 32].

Como etapa de pré-processamento, todas as imagens foram normalizadas para a resolução espacial de 256×256 pixels[cite: 33].

B. Geração Automática de Ground Truth

Dada a complexidade e a subjetividade inerentes à anotação manual precisa em cenários de mimetismo severo, adotou-se uma estratégia de rotulagem automática baseada no algoritmo de Subtração de Fundo por Mistura de Gaussianas.

A metodologia fundamenta-se na modelagem probabilística do fundo estático (substrato foliar) para realizar a segregação de elementos de primeiro plano (*foreground*) através da detecção de desvios temporais. Visando mitigar ruídos de sensor e assegurar a consistência topológica das regiões de interesse, aplicou-se um pós-processamento baseado em operações de morfologia matemática, especificamente abertura e dilatação. Esta abordagem garantiu a geração de máscaras binárias objetivas, estritamente correlacionadas à dinâmica de movimento do alvo.

C. Engenharia de Features: Fluxo Óptico Denso

A extração da dinâmica temporal fundamentou-se no algoritmo de Fluxo Óptico Denso de Farneback, capaz de estimar o campo de vetores de deslocamento para todos os pixels da imagem. Para endereçar o desafio do deslocamento de baixa magnitude (movimento lento), introduziu-se um passo temporal (*temporal stride*) variável de $k = 5$ a $k = 15$ quadros. Adicionalmente, aplicou-se um pré-processamento via CLAHE (*Contrast Limited Adaptive Histogram Equalization*) para maximizar o contraste local e evidenciar microtexturas. Esta etapa mostrou-se crítica para mitigar o problema da abertura em superfícies homogêneas, viabilizando a convergência do algoritmo de fluxo sobre o substrato foliar.

D. Arquitetura da Rede Neural Proposta

A arquitetura base adotada foi a U-Net totalmente convolucional. Para a implementação da abordagem híbrida, a topologia da camada de entrada foi reconfigurada para processar tensores de dimensão $(256, 256, 6)$. Esta estrutura viabiliza uma estratégia de fusão precoce (*early fusion*), consistindo na concatenação, ao longo do eixo de profundidade, dos canais espaciais (RGB normalizado) e dos canais temporais (Fluxo Óptico). Notavelmente, os componentes de fluxo, representados no espaço de cor HSV, foram submetidos a uma ponderação escalar $\alpha = 5.0$. Este fator de amplificação tem por objetivo equalizar a magnitude dos gradientes durante o processo de *backpropagation*, prevenindo que a rede priorize características estáticas em detrimento da informação de movimento.

II. EXPERIMENTOS

Os experimentos foram conduzidos sequencialmente nos três datasets para avaliar a robustez do método:

- **Experimento 1 (Baseline):** U-Net padrão (RGB). Treinamento por 15 a 50 épocas. Objetivo: Avaliar a capacidade de detecção baseada puramente em características visuais.

- **Experimento 2 (Data Augmentation):** U-Net padrão com geradores de imagem aplicando rotação, zoom e espelhamento em tempo real. Treinamento por 25 a 50 épocas. Objetivo: Verificar se a generalização forçada compensa a falta de features visuais.
- **Experimento 3 (Híbrido):** U-Net Topologia Modificada (RGB + Fluxo). Treinamento por 15 a 50 épocas. Objetivo: Avaliar o impacto da informação temporal na segmentação.

III. RESULTADOS E DISCUSSÃO

A. Análise do dataset vermelho

B. Validação em Cenário de Controle (Dataset Red)

Preliminarmente, o *Dataset Red* foi estabelecido como cenário de controle (baseline) visando a validação funcional do *pipeline* e a calibração fina de hiperparâmetros. Conforme esperado, todas as arquiteturas avaliadas demonstraram convergência robusta e alta acurácia de segmentação. Este desempenho é atribuído à alta distinção espectral (contraste cromático) entre o objeto de interesse e o substrato, o que trivializa a extração de características espaciais pela rede neural, eliminando a ambiguidade na distinção figura-fundo.




Fig. 1. Resultados qualitativos do Experimento 1 (Cenário de Controle). Observa-se a segmentação precisa facilitada pelo alto contraste cromático entre o alvo e o substrato.

C. Padronização do Protocolo Experimental

Visando assegurar a consistência comparativa e a reprodutibilidade dos resultados nos cenários subsequentes (Datasets *Black* e *Green*), o protocolo de treinamento e a parametrização da engenharia de *features* foram replicados rigorosamente.

Os hiperparâmetros críticos foram fixados da seguinte forma:

- **Dinâmica Temporal:** A janela de amostragem para o cálculo do Fluxo Óptico foi definida com um passo temporal (*temporal stride*) de $\Delta t = 15$ quadros, visando capturar deslocamentos de baixa velocidade.
- **Ponderação de Features:** A magnitude dos vetores de movimento foi submetida a um coeficiente de

amplificação escalar $\alpha = 10.0$, reforçando a relevância dos gradientes temporais na camada de entrada.

- **Otimização:** O ciclo de aprendizado profundo (*Deep Learning training loop*) foi estendido por 50 épocas para garantir a plena convergência da função de perda em todos os conjuntos de dados.

D. Limitações em Cenários de Contraste de Luminância (*Dataset Black*)

A etapa subsequente de validação incidiu sobre o *Dataset Black*, caracterizado pela presença de um espécime de coloração escura. Neste cenário, observou-se uma limitação crítica das abordagens puramente espaciais: tanto a arquitetura U-Net padrão quanto a variante com *Data Augmentation* demonstraram incapacidade de segmentar o objeto.

A análise de erro indica que, apesar da diferença de luminância, a assinatura espectral do inseto apresentou baixa distinção em relação ao substrato foliar (*Musa spp.*), resultando em uma falha de convergência onde a rede priorizou a classe majoritária (fundo). Entretanto, a hipótese da dinâmica temporal foi corroborada: ao incorporar a componente de Fluxo Óptico Denso, o sistema superou a ambiguidade visual, detectando o alvo exclusivamente através de sua magnitude de deslocamento.




Fig. 2. Resultados qualitativos do Experimento 2. Nota-se a ineficácia das técnicas baseadas apenas em aparência (esquerda/centro) devido à baixa discriminação cromática, contrastando com a detecção precisa obtida pela fusão com Fluxo Óptico (direita).

Estes resultados corroboram que a limitação preponderante do sistema transcende a camuflagem espectral, residindo, primordialmente, no severo **Desbalanceamento de Classes**. Observa-se que a Região de Interesse (RoI) compreende uma fração residual ($< 0,5\%$) da dimensão espacial da imagem[cite: 60].

Consequentemente, a otimização da função de perda (*Loss Function*) estagnou em um mínimo local degenerado: a rede convergiu para uma solução trivial onde a classificação de todos os pixels como a classe majoritária (fundo) maximiza artificialmente a acurácia global para $> 99\%$ [cite: 61]. As técnicas de *Data Augmentation*, por preservarem a razão de ocupação espacial entre o objeto e o fundo, mostraram-se

insuficientes para retificar este viés estatístico inerente ao *dataset*.

E. Eficácia da Abordagem Híbrida (*Experimento 3*)

Os resultados obtidos no Experimento 3 evidenciam a robustez de generalização da abordagem proposta, a qual manteve desempenho consistente transversalmente aos três cenários avaliados (*Green, Red, Black*). A análise dos mapas de ativação sugere que a incorporação do Fluxo Óptico Denso operou, funcionalmente, como um mapa de saliência (*saliency map*) de alta magnitude.

Em contraste com a estaticidade dos canais RGB, a componente temporal introduziu valores de ativação significativos exclusivamente na Região de Interesse (RoI), garantindo uma alta relação sinal-ruído em relação ao fundo (*zero-motion*). Do ponto de vista da otimização, esta disparidade induziu a propagação de gradientes de erro elevados durante a etapa de *backpropagation*. Este mecanismo forçou a atualização dos pesos sinápticos focada na dinâmica do objeto, permitindo ao modelo transpor simultaneamente o viés estatístico do desbalanceamento de classes e a ambiguidade espectral da camuflagem.




Fig. 3. Comparativo de desempenho da Abordagem Híbrida. A coluna da direita demonstra a capacidade do modelo em segmentar corretamente o alvo em movimento, superando o mimetismo que falhou nas abordagens estáticas.

F. Análise Visual Qualitativa

A inspeção qualitativa das previsões finais revela uma estrita correlação espacial entre as máscaras de segmentação geradas e os campos de magnitude do Fluxo Óptico. Observa-se um fenômeno de intermitência na detecção: durante os intervalos de repouso do espécime (velocidade nula), a rede suprime a máscara de segmentação. Este comportamento confirma empiricamente a premissa de que a arquitetura aprendeu a priorizar a dinâmica temporal como *feature* discriminante primária, em detrimento das características estáticas de aparência.

IV. CONCLUSÃO

Este trabalho apresentou e validou uma metodologia híbrida robusta para a segmentação semântica de objetos de pequena

escala sob condições de camuflagem severa. As evidências experimentais permitem as seguintes conclusões:

- 1) **Insuficiência dos Atributos Espectrais:** Em cenários de *Small Object Detection* com severo desbalanceamento de classes, o contraste cromático isolado é insuficiente para evitar que redes CNN padrão convirjam para mínimos locais degenerados (predição de fundo total).
- 2) **Redefinição do Espaço de Otimização:** A fusão precoce (*Early Fusion*) do Fluxo Óptico Denso altera a natureza do problema de otimização. A tarefa é efetivamente transposta de um reconhecimento de padrões visuais complexo e ambíguo para uma tarefa de localização de intensidade de movimento, simplificando a convergência da rede.
- 3) **Invariância ao Contraste:** A abordagem proposta demonstrou eficácia transversal, superando tanto a barreira da camuflagem (mimetismo no *Dataset Green*) quanto o problema de representatividade espacial (escala reduzida nos *Datasets Red/Black*).

Para trabalhos futuros para a continuidade desta pesquisa, propõe-se a curadoria de um *dataset* adquirido *in-situ* (em campo), visando mitigar a lacuna de representatividade entre o ambiente controlado de simulação e a realidade agrícola. A validação dos modelos em cenários de produção é imperativa para avaliar a robustez dos algoritmos de Fluxo Óptico frente a variáveis estocásticas não modeladas na simulação atual, tais como variações abruptas de iluminação natural, oclusões parciais por sobreposição foliar e a presença de artefatos de movimento causados pela ação do vento

REFERENCES

- [1] O. Ronneberger, P. Fischer, and T. Brox, “U-net: Convolutional networks for biomedical image segmentation,” in *International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, Springer, 2015, pp. 234–241.
- [2] G. Farneback, “Two-frame motion estimation based on polynomial expansion,” in *Scandinavian Conference on Image Analysis (SCIA)*, Springer, 2003, pp. 363–370.
- [3] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.
- [4] Z. Zivkovic, “Improved adaptive Gaussian mixture model for background subtraction,” in *Proceedings of the 17th International Conference on Pattern Recognition (ICPR)*, 2004, vol. 2, pp. 28–31.
- [5] K. Simonyan and A. Zisserman, “Two-stream convolutional networks for action recognition in videos,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2014, pp. 568–576.
- [6] D.-P. Fan, G.-P. Ji, G. Sun, M.-M. Cheng, J. Shen, and L. Shao, “Camouflaged object detection,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020, pp. 2777–2787.
- [7] K. Zuiderveld, “Contrast limited adaptive histogram equalization,” in *Graphics Gems IV*, P. S. Heckbert, Ed. San Diego, CA, USA: Academic Press Professional, 1994, pp. 474–485.
- [8] L. C. Ngugi, M. Abelwahab, and M. Abo-Zahhad, “Recent advances in image processing techniques for automated leaf pest diagnosis: A review,” *Wireless Communications and Mobile Computing*, vol. 2021, pp. 1–22, 2021.
- [9] Z. Teed and J. Deng, “RAFT: Recurrent All-Pairs Field Transforms for Optical Flow,” in *European Conference on Computer Vision (ECCV)*, Springer, 2020, pp. 402–419.